Analisador Léxico para MicroPascal

Descrição

Este projeto implementa um **analisador léxico** para a linguagem **MicroPascal**, responsável por ler um arquivo de código-fonte, identificar tokens e categorizá-los de acordo com a gramática da linguagem. Os tokens reconhecidos incluem:

- **Identificadores**
- **Palavras reservadas**
- **Operadores** (+, -, *, /, >, <, =, etc.)
- **Símbolos** (parênteses, chaves, ponto e vírgula, etc.)
- **Números** (inteiros e reais)

O analisador lê o arquivo de entrada, realiza a análise léxica e gera um arquivo de saída contendo a lista dos tokens identificados, suas respectivas posições no código e a tabela de símbolos.

Diagrama do AFD

O diagrama abaixo ilustra o Automato Finito Determinístico (AFD) usado para reconhecer tokens na linguagem MicroPascal. Ele mostra como o analisador léxico identifica diferentes tokens a partir de seus estados e transições.

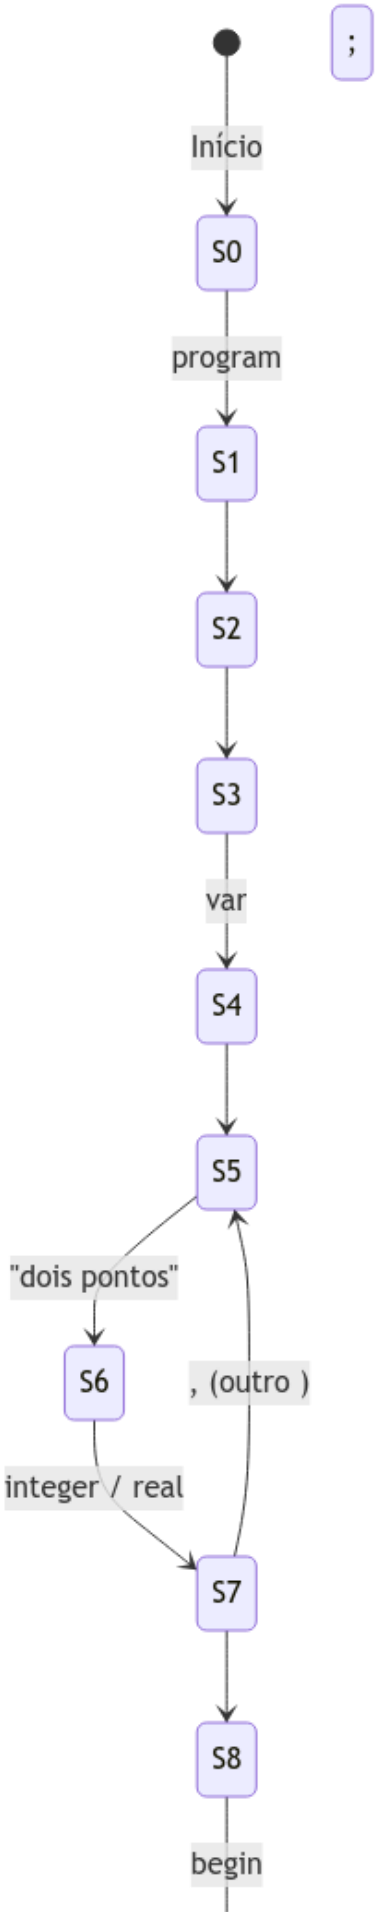
;
Início
S0
program
S1
S2
S3
var
S4
S5
"dois pontos"
S6
, (outro)
integer / real
S7
S8
begin

Funcionalidades

- **Análise léxica completa**: Reconhecimento de tokens válidos conforme as regras da linguagem MicroPascal.
- **Relatório de erros léxicos**: Detecção e notificação de caracteres inválidos, strings e comentários não fechados, com indicação precisa da linha e coluna.
- **Tabela de símbolos**: Armazena palavras reservadas e identificadores únicos.
- **Ignora espaços e comentários**: Espaços em branco, quebras de linha e comentários são ignorados durante a análise.
- **Arquivo de saída**: Geração de arquivo `.lex` com tokens reconhecidos e sua posição no código.

Estrutura do Código

Funções Principais

`int main(int argc, char *argv[])`

Coordena a execução do analisador léxico.

- **Parâmetros**:
  - `argc`: Número de argumentos passados ao programa.
  - `argv[]`: Lista de argumentos.
    - `argv[1]`: Arquivo de entrada.
- **Descrição**:
  - Verifica a presença de um arquivo de entrada.
  - Abre o arquivo de entrada e cria o arquivo de saída.
  - Realiza a análise chamando `analisar_lexico()`.

`void exibir_ajuda(const char *nome_programa)`

Exibe instruções detalhadas sobre como usar o analisador.

- **Parâmetros**:
  - `nome_programa`: Nome do executável.

`void exibir_lista_de_tokens()`

Mostra a lista de tokens reconhecidos pelo analisador.

`void analisar_lexico(FILE *arquivo, FILE *saida)`

Realiza a análise léxica do arquivo de entrada e escreve os tokens no arquivo de saída.

- **Descrição**:
  - Processa o arquivo, identificando e categorizando os tokens.
  - Tokens são gravados no arquivo no formato `<TOKEN_NOME, TOKEN_LEXEMA> na linha X, coluna Y`.

*Token obter_token(FILE *arquivo)*

Identifica e retorna o próximo token do arquivo de entrada.

void iniciar_tabela_de_simbolos()

Inicializa a tabela de símbolos com as palavras reservadas da linguagem MicroPascal.

*void reportar_erro(char *mensagem, int linha, int coluna)*

Exibe uma mensagem de erro com a linha e a coluna do problema.

Estruturas

typedef struct Token

Estrutura que define um token.

- **Campos**:
  - `char nome[MAX_TOKEN_LENGTH]`: Nome do token.
  - `char lexema[MAX_TOKEN_LENGTH]`: Lexema do token.
  - `int linha`: Linha do token.
  - `int coluna`: Coluna do token.

Arquivo de Saída

O arquivo de saída é gerado com o nome do arquivo de entrada acrescido da extensão `.lex`. Contém uma linha para cada token reconhecido, no seguinte formato:

```
<TOKEN_NOME, TOKEN_LEXEMA> na linha X, coluna Y
```

Exemplo:

```
<ID, program> na linha 1, coluna 1
<ID, exemplo> na linha 1, coluna 9
<SMB_OPA, ( > na linha 1, coluna 16
...
```

Executando o Programa

Sintaxe

```
./analisador_lexico <arquivo_de_entrada>
```

Opções

- `-h` ou `--help`: Exibe a ajuda.
- `--tokens`: Lista os tokens suportados.

Exemplos

1. Para analisar um arquivo de código MicroPascal:

```
./analisador_lexico programa.pas
```

2. Para listar os tokens reconhecidos:

```
./analisador_lexico --tokens
```

Tokens Suportados

Palavras Reservadas

- `program`, `var`, `integer`, `real`, `begin`, `end`, `if`, `then`, `else`, `while`, `do`, `write`, `read`

Operadores

- `+` (Adição)
- `-` (Subtração)
- `*` (Multiplicação)
- `/` (Divisão)
- `=` (Atribuição)
- `>` (Maior que)
- `>=` (Maior ou igual)
- `<` (Menor que)
- `<=` (Menor ou igual)
- `<>` (Diferente)
- `:=` (Atribuição)

Símbolos

- `;` (Ponto e vírgula)
- `,` (Vírgula)
- `{` (Chave de abertura)
- `}` (Chave de fechamento)
- `(` (Parêntese de abertura)
- `)` (Parêntese de fechamento)
- `.` (Ponto final)
- `:` (Dois pontos)

Outros Tokens

- `ID` (Identificadores)
- `NUM` (Números)

Relatório de Erros Léxicos

O analisador gera mensagens de erro como:

```
Erro léxico: Caractere inválido na linha X, coluna Y
```

Exemplos de programas

Programa Corretos

1. **Programa 1: Simples Atribuição**

```
program Teste1;
var
   a: integer;
begin
   a := 10;
   writeln(a);
end.
```

2. **Programa 2: Condicional**

```
program Teste2;
var
   x: real;
begin
   x := 5.5;
   if x > 5 then
      writeln('x é maior que 5');
end.
```

3. **Programa 3: Laço While**

```
program Teste3;
var
   i: integer;
begin
   i := 1;
   while i <= 10 do
   begin
      writeln(i);
      i := i + 1;
   end;
end.
```

Programas com Erros Léxicos

1. **Erro 1: Caractere Inválido**

```
program TesteErro1;
var
   a: integer;
begin
   a := 10$; // Caractere inválido '$'
   writeln(a);
end.
```

2. **Erro 2: Identificador Inválido**

```
program TesteErro2;
var
   1a: integer; // Identificador não pode começar com número
begin
   1a := 5;
```

```
   writeln(1a);
end.
```

3. **Erro 3: Operador Inválido**

```
program TesteErro3;
var
   b: integer;
begin
   b := 10 & 5; // Operador inválido '&'
   writeln(b);
end.
```

Esses exemplos fornecem uma boa variedade para testar o seu analisador léxico. Se precisar de mais alguma coisa, é só avisar!

Requisitos

- **Compilador C**: GCC ou equivalente para compilar o projeto.

  Exemplo de comando:

  ```
  gcc -o analisador_lexico lexer.c main.c
  ```